[2017 Winter]

Tensorflow Tutorial

02. 이미지 분류를 위한 첫 번째 신경망

학습 목표

- 간단한 image classification 문제를 다룬다.
- Python에서 이미지 파일을 읽고 처리하는 방법들을 익힌다.
- Tensorflow를 이용하여 기본적인 신경망을 구성해본다.
  - 학습 데이터 전체를 메모리에 load할 수 있을 정도의 규모에서 사용할 수 있는 방법
  - Fully connected layer로만 구성된 신경망

- Google 이미지 검색에서 cat, dog, sheep, cow, pig 각각 100장씩 이미지를 확보하였다. 여기서 다운로드 한다.
- 압축을 풀면 동물 종류별로 5개의 서브 디렉토리를 가진 animal_images 디렉토리가 나온다. (mac에서 만든 압축 파일이라서 압축을 해제하면 _MACOSX라는 폴더가 생성되는데 그냥 삭제한다.)
- 이 디렉토리를 적절한 위치에 옮겨둔다. 이 튜토리얼에서 앞으로 만들 프로젝트들을 저장할 폴더를 적절한 위치에 만들고 그 안에 animal_images 디렉토리를 옮겨둔다.

사용할 이미지 데이터의 준비

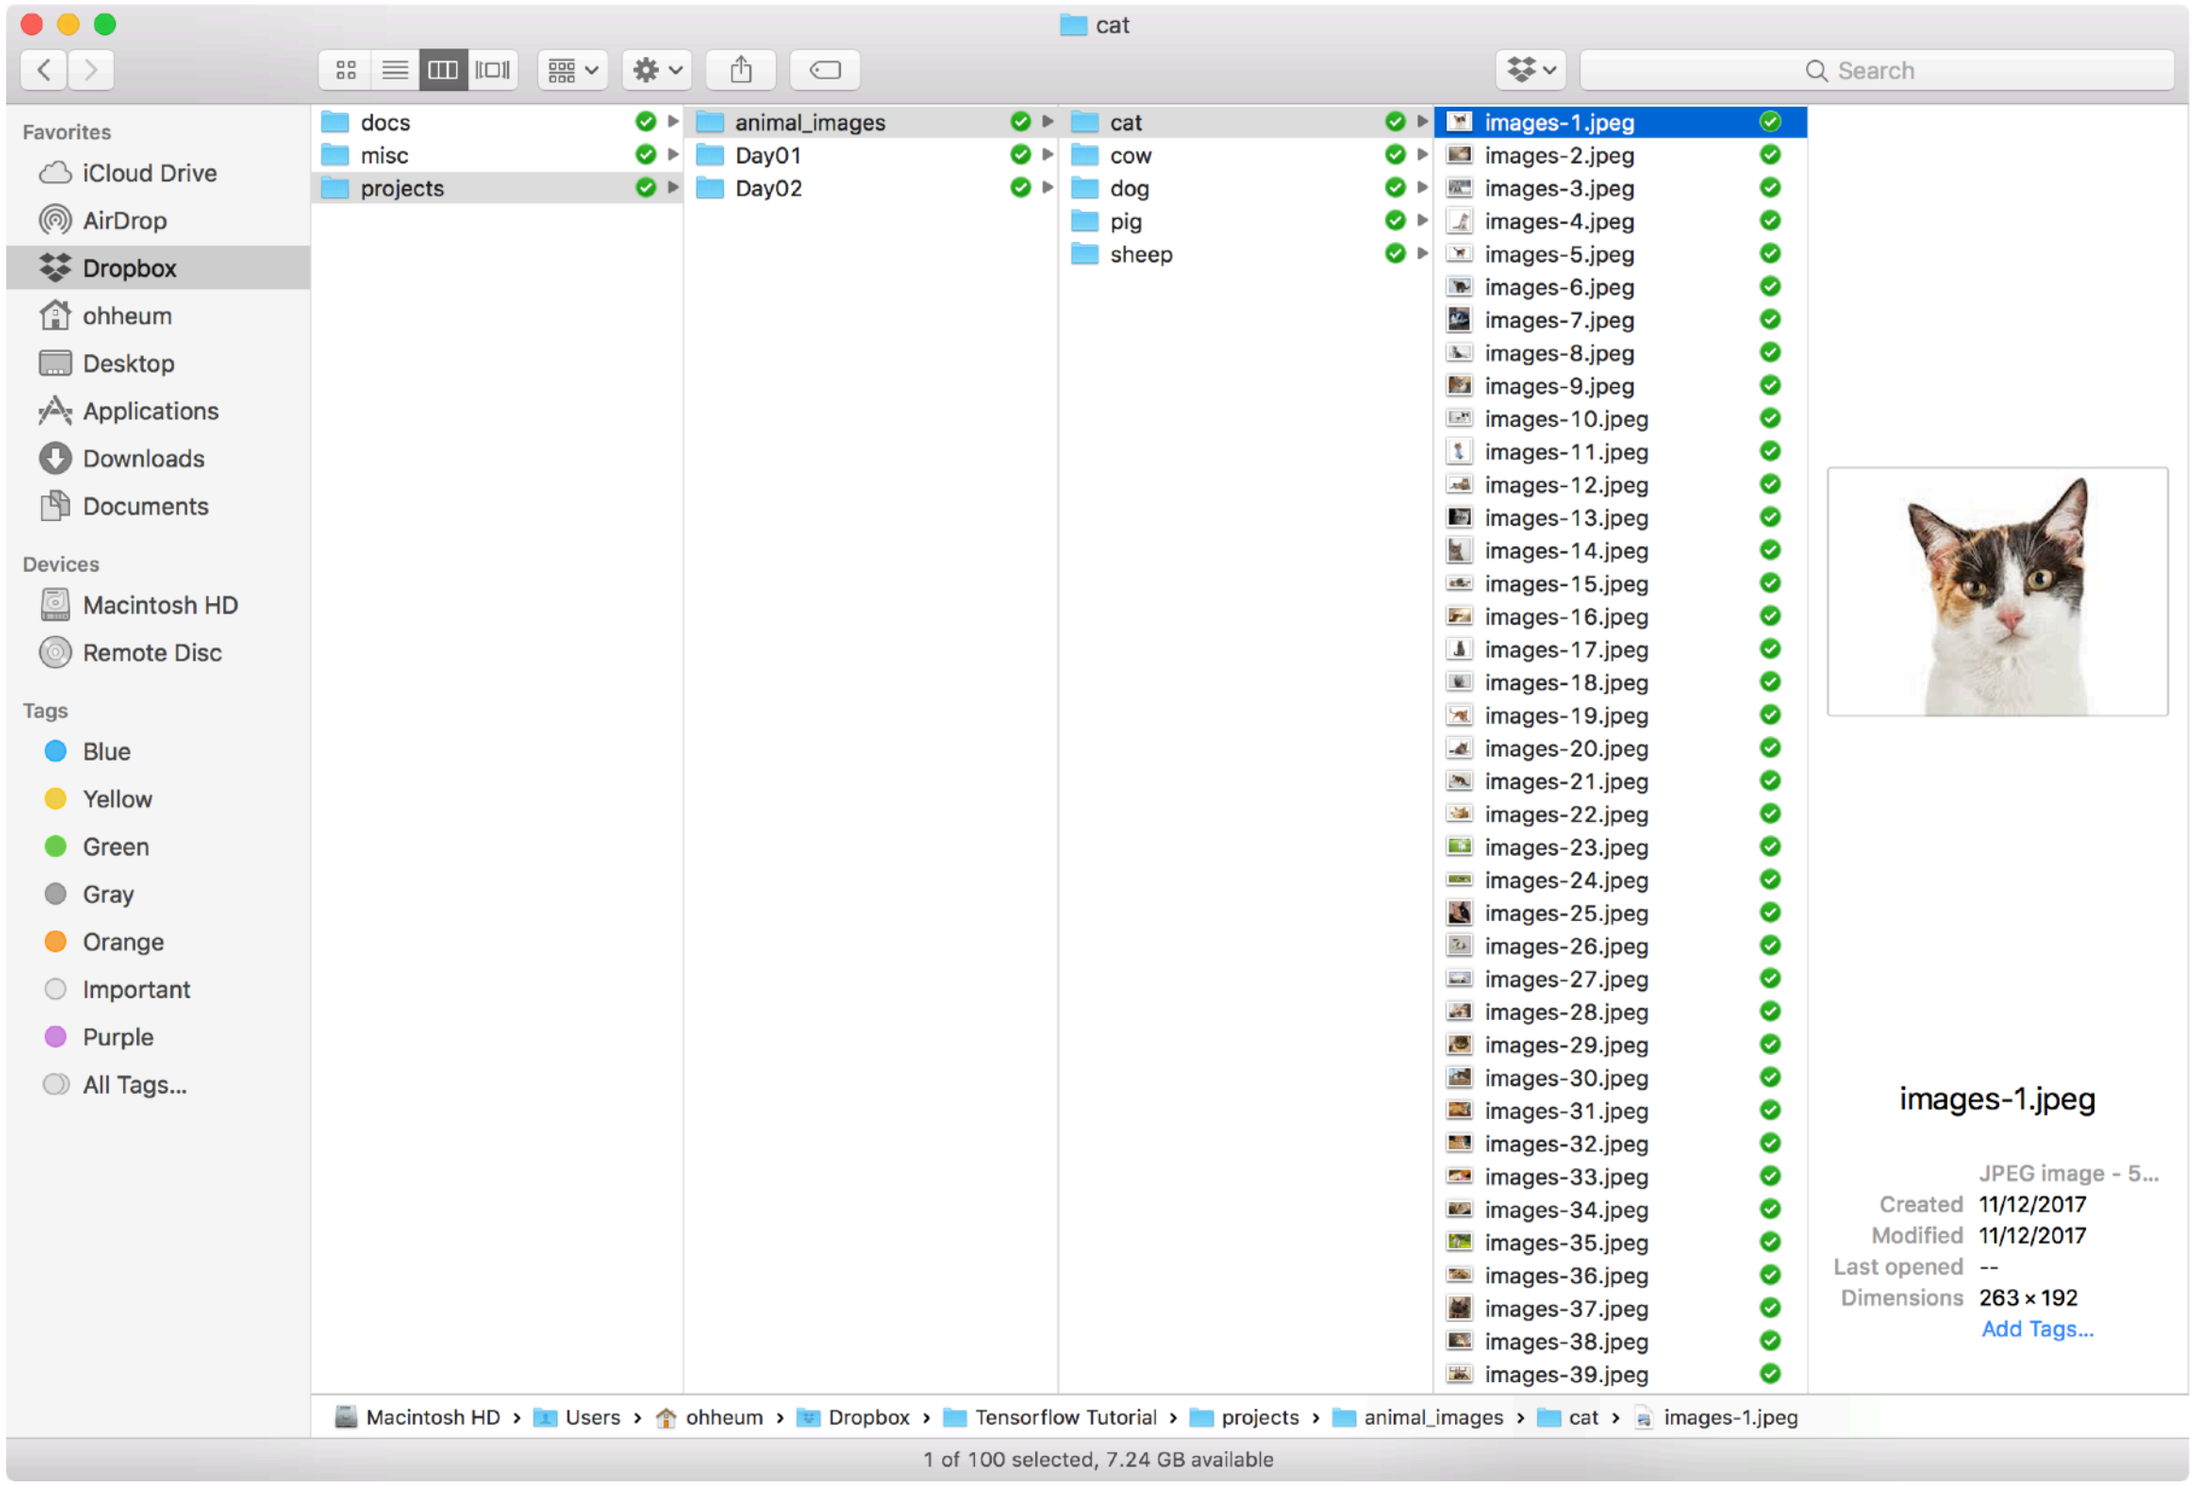

- **Handling mages**
  - **PIL (Python Image Library)**: discontinued
  - **Pillow**: PIL fork, actively maintained
  - **OpenCV**: primarily for vision
  - **Tensorflow** 자체도 image handling library를 제공
- **Matplotlib**
  - for various **plotting**

code01.py

https://docs.opencv.org/3.1.0/dc/d2e/tutorial_py_image_display.html

- opencv를 이용하여 이미지를 프로그램 내로 load하고 간단한 조작을 하는 것을 연습한다.
- 프로그램 내에서 이미지는 numpy array로 저장된다. numpy array의 기본적인 사용법을 python list와 비교해서 어느정도 습득해야 한다.

```
import numpy as np
import os
import cv2

image_path = '../animal_images/cat/images-1.jpeg'

img = cv2.imread(image_path)
```

← img는 numpy array이다.

```
print(img.ndim)
print(img.shape)
print(img.dtype)
```

← numpy array가 가진 기본 attribute들을 확인해 본다.

```
print(img)
print(img.tolist())
```

- cv2.imread() 함수의 2번째 매개변수로 다음 중 하나를 지정할 수 있다.
  - cv2.IMREAD_COLOR: default flag
  - cv2.IMREAD_GRAYSCALE: grayscale mode
  - cv2.IMREAD_UNCHANGED: include alpha channel
- 모드를 바꿔가면서 테스트해본다.

code01.py

https://docs.opencv.org/3.1.0/dc/d2e/tutorial_py_image_display.html

- 이미지를 화면에 display하고, resize하고, 이미지 파일로 저장하고, color space를 변환하는 일을 해본다.

```
cv2.imshow('Test Image', img)
cv2.waitKey(0) & 0xFF
cv2.destroyAllWindows()
```

← 이미지를 화면에 display한다. 아무 키나 누르면 사라진다.

```
img = cv2.resize(img, (200, 200), interpolation=cv2.INTER_CUBIC)  # resize
img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)  # cv2 load images as BGR, convert it to RGB
```

```
cv2.imwrite('converted.jpg', img)
```

← 이미지를 파일로 저장한다.

1. https://www.youtube.com/watch?v=rN0TREj8G7U
2. https://www.youtube.com/watch?v=a8aDcLk4vRc&list=PLeo1K3hjS3uset9zlVzJWqplaWBiacTEU&index=2
3. https://www.youtube.com/watch?v=_d_Ka-ks2a0&list=PLeo1K3hjS3uset9zlVzJWqplaWBiacTEU&index=3
4. https://www.youtube.com/watch?v=XawR6CjAYV4&list=PLeo1K3hjS3uset9zlVzJWqplaWBiacTEU&index=4

data visualization package

data plotting module

```
from matplotlib import pyplot as plt

plt.imshow(img)
plt.show()
```

matplotlib 패키지가 설치되어 있지 않으면 이 부분에서 오류가 난다.
커서를 이 부분에 위치시키고 Alt-Enter를 누르면 “install package matplotlib”라는 메뉴가 생기는데 이것을 실행한다.
혹은 Anaconda Prompt를 실행하고 다음과 같이 설치해도 된다.

```
$ activate tfenv3.5
$ conda install matplotlib
```

```
def plot_images(image):
    # Create figure with 4x4 sub-plots.
    fig, axes = plt.subplots(4, 4)
    fig.subplots_adjust(hspace=0.3, wspace=0.3)

    for i, ax in enumerate(axes.flat):

        row = i // 4
        col = i % 4
        image_frag = image[row*50:(row+1)*50, col*50:(col+1)*50, :]
        ax.imshow(image_frag)


        xlabel = '{},{}'.format(row, col)
        ax.set_xlabel(xlabel)

        ax.set_xticks([])   # Remove ticks from the plot.
        ax.set_yticks([])

    plt.show()


plot_images(img)
```

이미지를 가로 세로 4조각으로 분할(slicing)해본다.

이 함수를 호출해 본다.

- cv2.imread()함수에서 이미지를 grayscale로 읽어들여서 프로그램 내부에서 어떻게 표현되는지 살펴본다.
- code01.py에서 읽은 이미지의 일부를 crop하여 display하거나 이미지 파일로 저장해 본다.
- 이미지를 채널별로 따로 분리하여 display하거나 저장해본다.

code02.py에서는 준비한 모든 이미지들을 프로그램으로 읽어와서 저장하고, 배치 단위로 분할하는 일을 해본다.

```
import numpy as np
import os
import cv2

IMG_HEIGHT = 60
IMG_WIDTH = 60
NUM_CHANNEL = 3
NUM_CLASS = 5
```

이미지 크기는 60*60으로 resize해서 사용할 계획이다.
NUM_CLASS는 분류할 동물 종류의 가지 수이다.

```
def load_image(addr):
    img = cv2.imread(addr)
    img = cv2.resize(img, (IMG_HEIGHT, IMG_WIDTH), interpolation=cv2.INTER_CUBIC)
    img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)

    img = img.astype(np.float32)

    return img
```

unit8 타입의 데이터를 float32 타입으로 변환하였다.

code02.py

Load All Images into Memory

```
IMAGE_DIR_BASE = '../animal_images'

image_dir_list = os.listdir(IMAGE_DIR_BASE)

print(image_dir_list)
```

os.listdir 함수를 이용하여 디렉토리에 속한 파일과 서브 디렉토리의 목록를 읽는다.

glob 패키지를 이용하면 와일드 카드를 사용하여 좀 더 편리하게 파일 목록을 얻을 수 있다.

- import glob
- file_names = glob.glob('../animal_images/cat/*.jpg');

- 보통 데이터(우리의 경우 동물 이미지)를 feature, 정답(분류)을 label이라고 부른다.
- 모든 이미지들을 하나의 Python list로 저장하고, 각 이미지의 라벨은 0(cat), 1(cow), 2(dog), 3(pig), 4(sheep)으로 표시하여, feature에 이미지가 저장된 순서대로 labels 리스트에 저장한다.

```
class_index = 0

features = []
labels = []

for dir_name in image_dir_list:
    image_file_list = os.listdir(IMAGE_DIR_BASE + os.sep + dir_name)
    for file_name in image_file_list:
        image = load_image(IMAGE_DIR_BASE + os.sep + dir_name + os.sep + file_name)

        features.append(image.ravel())
        labels.append(class_index)

    class_index += 1

print(len(features))    # just for test
```

features와 labels는 empty Python list이다.
Python list가 numpy array보다 조작이 쉬운 면이 있다.

ravel()은 다차원 배열을 1차원 배열로 변환

append는 Python 리스트에 새로운 값을 추가한다.

디렉토리가 바뀔 때
label값을 증가시켜 주었다.

```
from random import shuffle
shuffle_data = True
if shuffle_data:
    c = list(zip(features, labels))
    shuffle(c)
    features, labels = zip(*c)

features = np.array(features)
labels = np.array(labels)
```

features와 labels는 Python tuple이다. np array로 변환해준다.

Python built-in list와 zip 함수

```
>>> x = [1, 2, 3]
>>> y = [4, 5, 6]
>>> zipped = zip(x, y)
>>> print(zipped)
<zip object at 0x10d9d9f88>
>>> zipped_list = list(zipped)
>>> print(zipped_list)
[(1, 4), (2, 5), (3, 6)]
>>> x2, y2 = zip(*zipped_list)
>>> print(x == list(x2) and y == list(y2))
True
```

```
print(len(labels))
print(labels)
print(labels.shape)

image = features[0]
image = image.reshape((IMG_HEIGHT, IMG_WIDTH, NUM_CHANNEL))
image = image.astype(np.uint8)
cv2.imshow('Restored Image', image)
cv2.waitKey(0) & 0xFF
cv2.destroyAllWindows()
```

제대로 되고 있는지
확인하기 위해서
이런 저런 테스틀를 해본다.

- 데이터를 training set과 test set으로 분할하였다. 8:2의 비율이 일반적으로 사용된다.
- Validation data set은 언제까지 training을 지속할지 결정하기 위해서 사용되며, validation data를 사용할 경우 보통 6:2:2의 비율로 분할한다.
- 우리는 당분간 validation data를 사용하지 않는다.

```
train_features = features[0:int(0.8 * len(features))]
train_labels = labels[0:int(0.8 * len(labels))]

# val_features = features[int(0.6 * len(features)):int(0.8 * len(features))]
# val_labels = labels[int(0.6 * len(features)):int(0.8 * len(features))]

test_features = features[int(0.8 * len(features)):]
test_labels = labels[int(0.8 * len(labels)):]
```

Python Generator의 예

generator_test.py

```
import math

def is_prime(number):
    if number <= 1:
        return False
    if number == 2:
        return True
    if number % 2 == 0:
        return False
    for div in range(3, int(math.sqrt(number) + 1), 2):
        if number % div == 0:
            return False
    return True
```

- Python generator는 generator iterator를 반환하는 함수이다.
- Generator iterator에 대해서 next()가 함수가 호출될 때 함수의 시작부터가 아니라 이전 호출에서 yield를 실행한 다음부터 실행이 재개되어 다음 yield가 실행될 때 까지 진행된다.
- 반복된 호출에서 함수의 상태(지역변수의 값)는 보존된다.

```
def get_primes(number):
    while True:
        if is_prime(number):
            yield number
        number += 1
```

매개변수 number보다 크거나 같은 모든 소수를 순서대로 생성해주는 generator

```
prime_iterator = get_primes(1)

for _ in range(100):

    next_prime_number = next(prime_iterator)

    print(next_prime_number)
```

```
BATCH_SIZE = 50

def train_data_iterator():
    batch_idx = 0
    while True:
        idxs = np.arange(0, len(train_features))
        np.random.shuffle(idxs)
        shuf_features = train_features[idxs]
        shuf_labels = train_labels[idxs]

        batch_size = BATCH_SIZE

        for batch_idx in range(0, len(train_features), batch_size):
            images_batch = shuf_features[batch_idx:batch_idx+batch_size] / 255.
            images_batch = images_batch.astype("float32")
            labels_batch = shuf_labels[batch_idx:batch_idx+batch_size]
            yield images_batch, labels_batch
```

매 epoch마다 새로 shuffling한다.

255로 나누어서 0에서 1사이의
실수로 정규화 한다.
(반드시 필요한건 아니다.)

```
iter_ = train_data_iterator()
for step in range(100):
```

generator를 호출하면 iterator를 반환한다.

```
    # get a batch of data
    images_batch_val, labels_batch_val = next(iter_)

    print(images_batch_val)
    print(labels_batch_val)
```

iterator에 대해서 next함수를 실행할 때마다
하나의 배치가 반환된다.

Tensorflow

Symbolic Representation of Computation

$$x : 1 \times 10800 \text{ vector}$$
$$y : 1 \times 5 \text{ vector}$$
$$W_1 : 10800 \times 1024 \text{ matrix}$$
$$b_1 : 1 \times 1024 \text{ vector}$$
$$fc_1 = S(xW_1 + b_1)$$
$$W_2 : 1025 \times 5 \text{ matrix}$$
$$b_2 : 1 \times 5 \text{ vector}$$
$$y\_ = fc_1 \cdot W_2 + b_2$$

$$\text{Let } x = [123, 8, 67, 12, \ldots, 98]$$
$$\text{Then } y\_ = ?$$

- 고등학교때까지의 기억을 되살려보면 이런 식의 symbolic representation이 procedural한 코드보다 우리에게 훨씬 익숙한 방식이다.
- 먼저 변수들 간의 관계를 수식 혹은 함수로 기술하고, 계산은 나중에 한다.
- Tensorflow는 이런 방식의 symbolic representation을 사용한다.

Symbolic Representation of Computation

$$x : 1 \times 10800 \text{ vector}$$
$$y : 1 \times 5 \text{ vector}$$
$$W_1 : 10800 \times 1024 \text{ matrix}$$
$$b_1 : 1 \times 1024 \text{ vector}$$
$$fc_1 = S(xW_1 + b_1)$$
$$W_2 : 1025 \times 5 \text{ matrix}$$
$$b_2 : 1 \times 5 \text{ vector}$$
$$y\_ = fc_1 \cdot W_2 + b_2$$

이 부분에서는 실제로 어떤 계산도 일어나지 않는다.
아래 그림과 같은 그래프를 구성할 뿐이다.

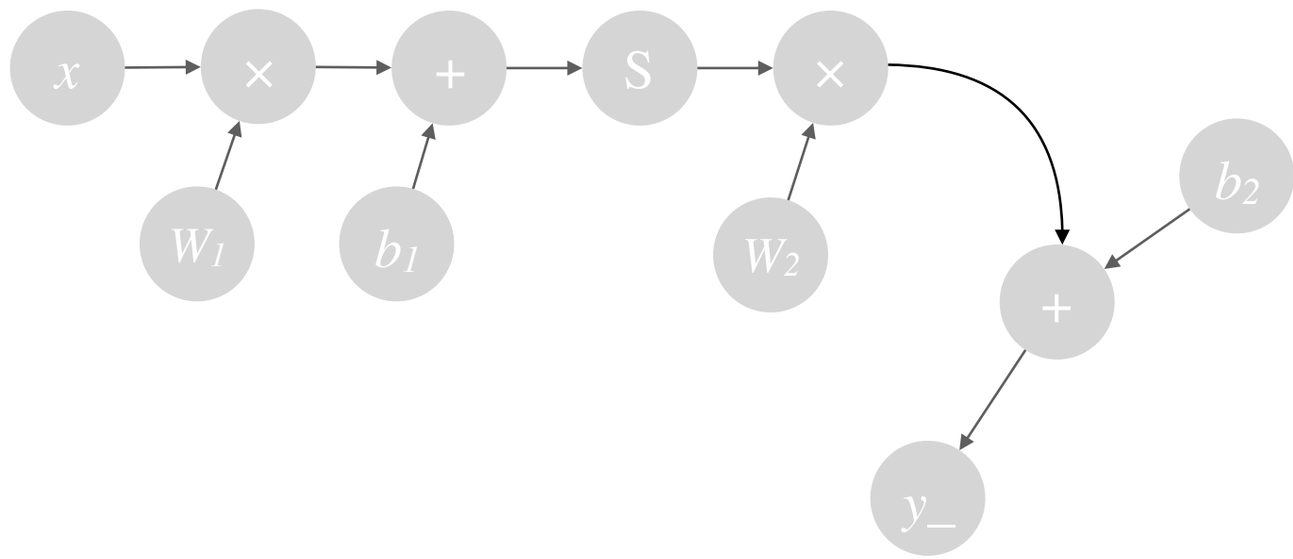

Let $x = [123, 8, 67, 12, \ldots, 98]$ ← 여기에서 x의 값이 제공된다.

Then $y\_ = ?$ ← y_의 값을 물어볼때 드디어 위의 그래프가 순서대로 계산된다.

Symbolic Representation of Computation

$$x : 1 \times 10800 \text{ vector}$$
$$y : 1 \times 5 \text{ vector}$$

나중에 실제로 제공될 입력 데이터가
들어갈 자리를 placeholder라고 부른다.

$$W_1 : 10800 \times 1024 \text{ matrix}$$
$$b_1 : 1 \times 1024 \text{ vector}$$
$$W_2 : 1025 \times 5 \text{ matrix}$$
$$b_2 : 1 \times 5 \text{ vector}$$

Weight와 bias가 저장될 변수들을 그냥 변수(variable) 혹은
model variable이라고 부른다.

$$fc_1 = S(xW_1 + b_1)$$
$$y\_ = fc_1 \cdot W_2 + b_2$$

일어나야할 계산들을 표현하는 노드들이다.
뭉뚱그려서 모델(model)이라고 부른다.

실제 계산을 하기전에 이 부분에서 Session을 생성해야 한다.
Session은 실제 계산을 수행하는 프로세스 정도로 이해하고 넘어가자.

$$\text{Let } x = [123, 8, 67, 12, \ldots, 98]$$
$$\text{Then } y\_ = ?$$

Placeholder에 입력 데이터를 제공하고,
내가 알고싶은 값을 지정하면서
session을 run하면 계산 결과가 반환된다.

- **Placeholder**: 그래프에 입력(features, labels 등)을 공급하는 장소로 사용됨
- **Model variable**: 가중치(weight)와 바이어스(bias) 값을 저장
- Placeholder의 입력과 변수로 부터 출력을 계산하는 함수(모델)
- **Cost (loss) 함수**: 정답(label)과 실제 출력의 차이를 표현하는 오류 함수
- 최적화 알고리즘(optimization method): Gradient descent 알고리즘으로 변수의 값을 갱신

네트워크 설계

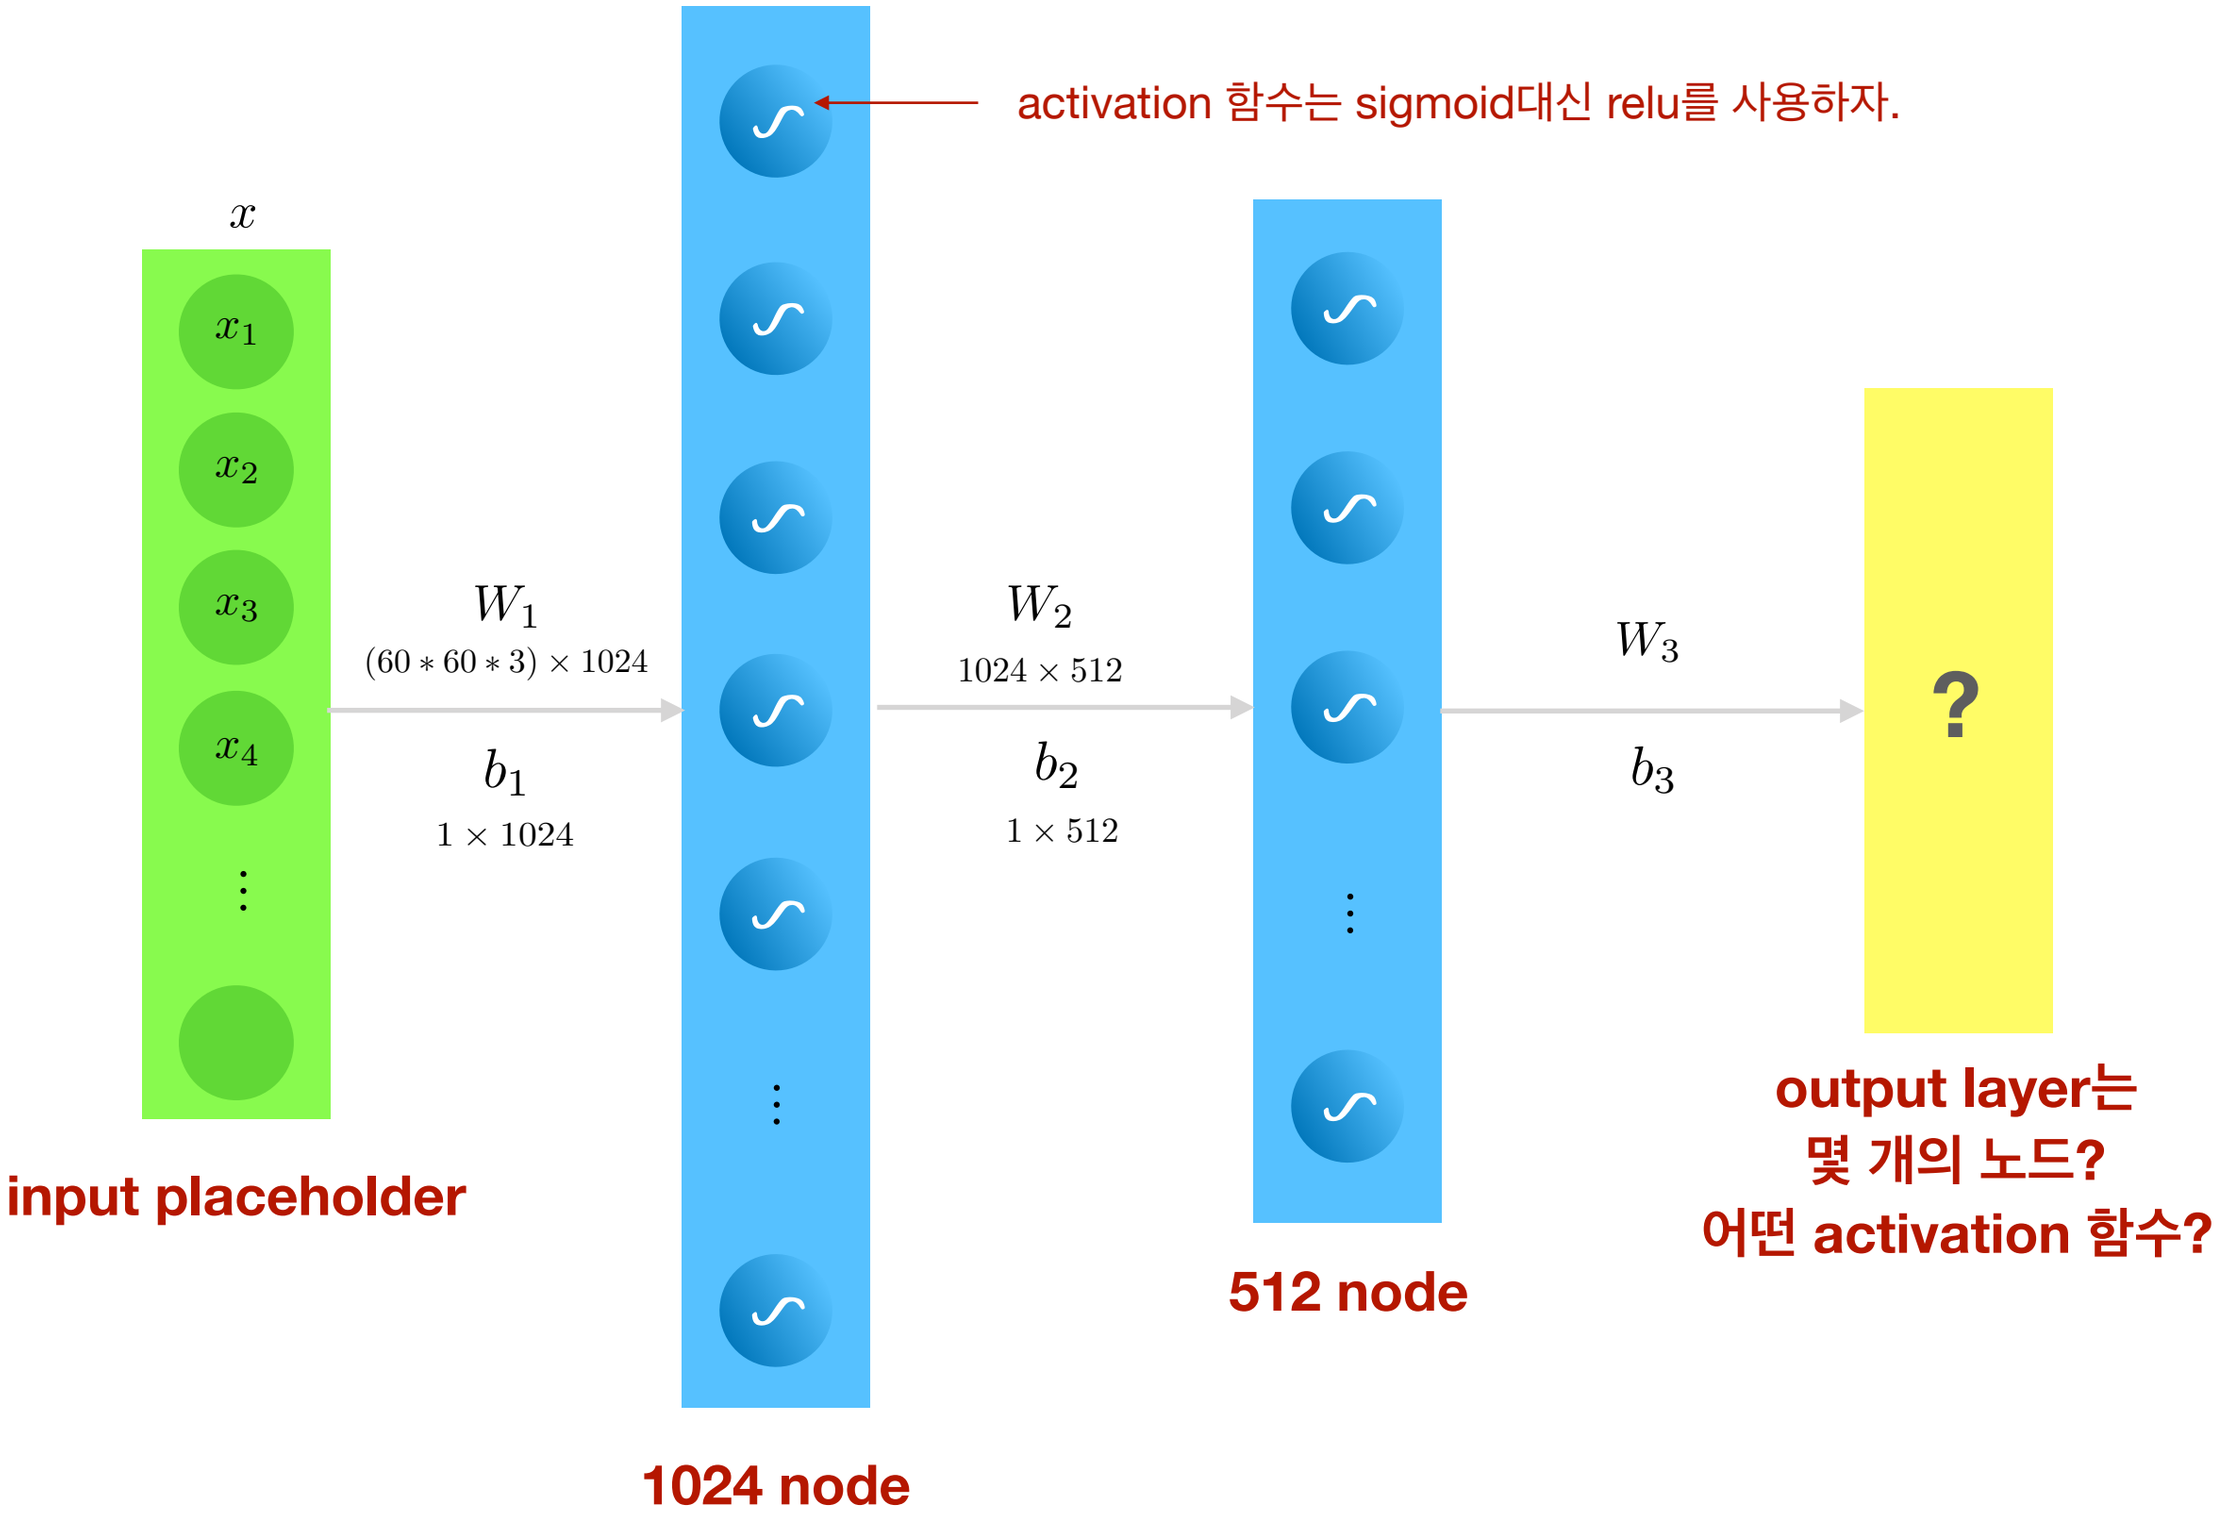
activation 함수는 sigmoid대신 relu를 사용하자.
x
x_1
x_2
x_3
x_4
W_1
$(60 * 60 * 3) \times 1024$
b_1
1×1024
W_2
1024×512
b_2
1×512
W_3
b_3
?
input placeholder
1024 node
512 node
output layer는
몇 개의 노드?
어떤 activation 함수?

One-Hot Encoding

- 이미지 classification 문제에서는 label과 네트워크의 출력을 one-hot encoding으로 표현하는 것이 일반적이다.
- 클래스의 개수가 k개일 때 각각의 이미지에 대해서 라벨과 출력을 k-차원 벡터로 표현한다. 해당 이미지가 소속된 클래스에 해당하는 하나의 값만 1이고 나머지는 모두 0이다.
  - 우리의 예에서 클래스의 개수는 5개이고, 순서는 cat, cow, dog, pig, sheep라고 하자.
  - cat은 [1, 0, 0, 0, 0]으로, cow는 [0, 1, 0, 0, 0], dog는 [0, 0, 1, 0, 0], pig는 [0, 0, 0, 1, 0], 그리고 sheep는 [0, 0, 0, 0, 1]로 표현한다.
- **그냥 0, 1, 2, 3, 4와 같이 하나의 스칼라 값으로 표현하는 것이 적절하지 않은 이유는?**
- **우리의 경우 label은 one-hot-encoding으로 표현되어 있지 않다.**

네트워크 설계

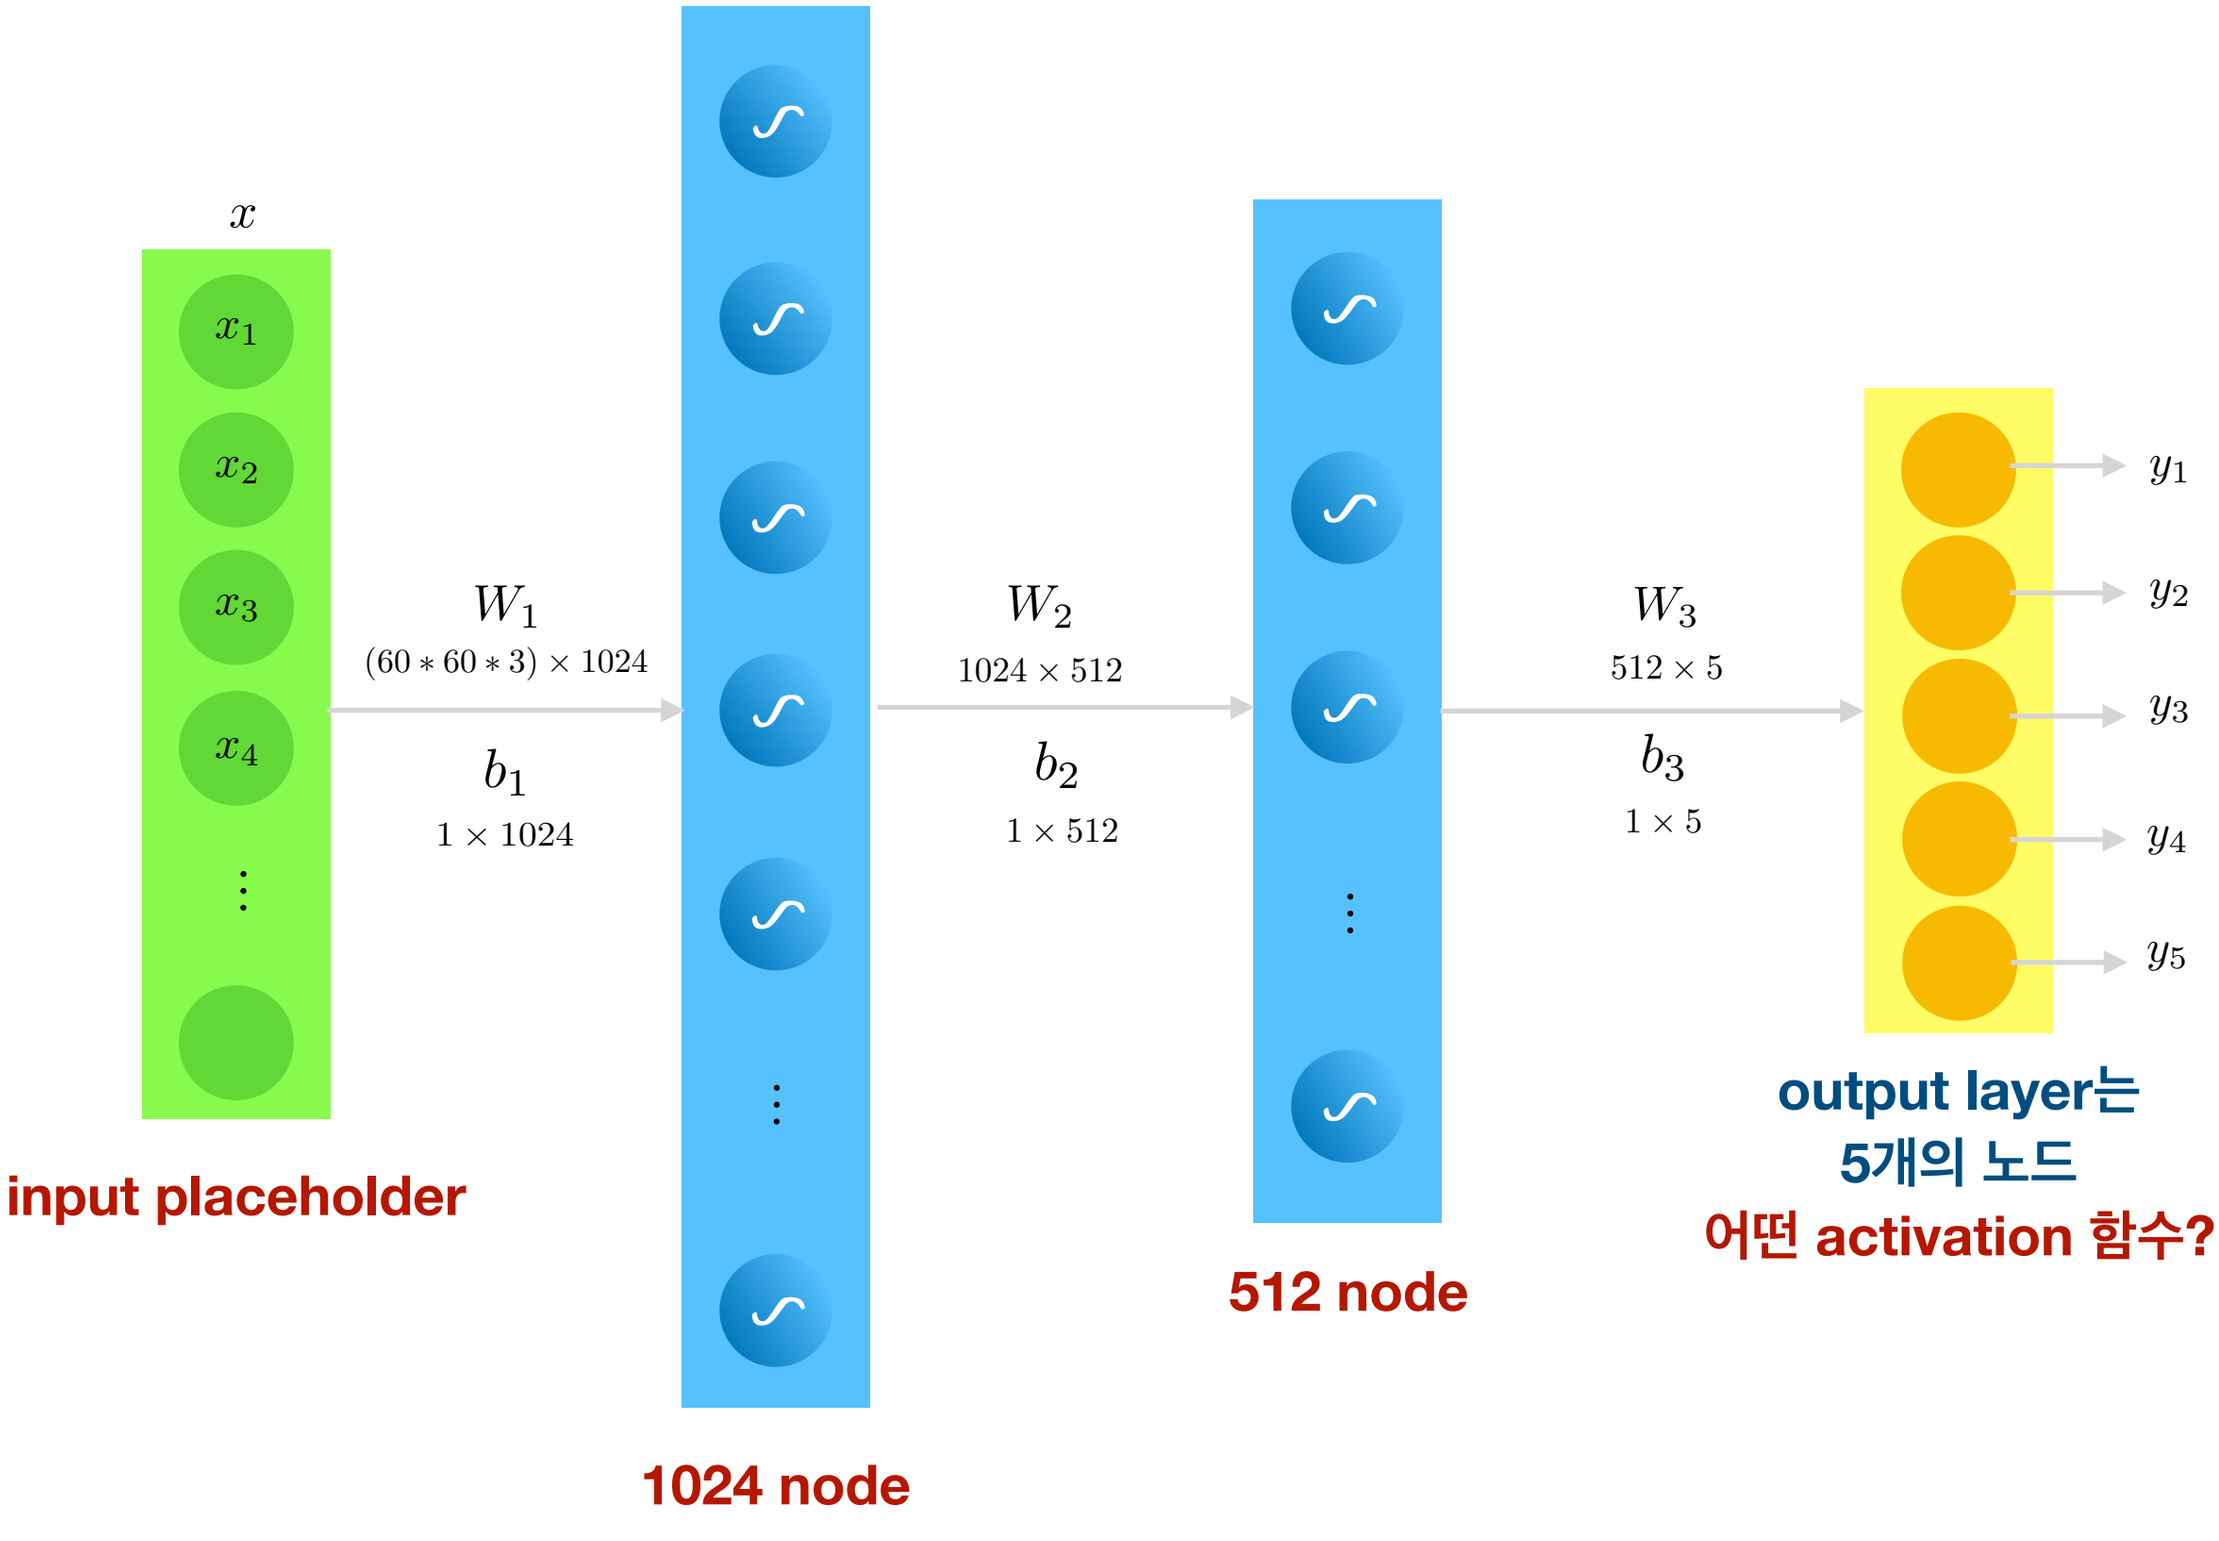
x
x_1
x_2
x_3
x_4
W_1
$(60 * 60 * 3) \times 1024$
b_1
1×1024
W_2
1024×512
b_2
1×512
W_3
512×5
b_3
1×5
y_1
y_2
y_3
y_4
y_5
input placeholder
1024 node
512 node
output layer는
5개의 노드
어떤 activation 함수?

- classification 문제에서 출력 벡터 (우리의 경우 5차원 벡터)는 해당 이미지가 각 클래스에 속할 확률을 표현하면 자연스럽다.
- 임의의 K차원 벡터 $z = [z_1, z_2, \ldots, z_K]$를 크기 순서를 유지하면서 각 원소가 0 ~ 1범위에 들어가고 합이 1이 되도록 변환해주는 함수가 softmax 함수이다.

$$\sigma : \mathbb{R}^K \to [0,1]^K$$

$$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}} \quad \text{for } j = 1, \ldots, K.$$

- softmax함수는 classification 문제에서 출력층에서 흔히 사용되는 activation 함수이다.

Constructing Graph: Placeholder

- 이미지는 images_batch라는 이름의 placeholder를 통해서 네트워크에 공급한다.
- 라벨은 labels_batch라는 이름의 placeholder를 통해서 네트워크에 공급한다.
- 각각의 이미지는 IMG_HEIGHT*IMG_WIDTH*NUM_CHANNEL 크기의 1차원 벡터로 표현된다.

```
import tensorflow as tf
```

입력 이미지가 제공될 placeholder의 크기는 batch_size * image_size이다.

None은 나중에 실제로 제공되는 데이터의 크기에 맞춘다는 의미이다.

```
images_batch = tf.placeholder(dtype=tf.float32,
                              shape=[None, IMG_HEIGHT*IMG_WIDTH*NUM_CHANNEL])

labels_batch = tf.placeholder(dtype=tf.int32, shape=[None, ])
```

크기가 미정인 1차원 벡터의 shape은 이렇게 지정한다.

(이렇게 하면 label이 one-hot-encoding이 아님을 기억하자.)

https://www.tensorflow.org/api_docs/python/tf/placeholder

tf.placeholder

```
placeholder(
    dtype,
    shape=None,
    name=None
)
```

Defined in `tensorflow/python/ops/array_ops.py`.

See the guides: Inputs and Readers > Placeholders, Reading data > Feeding

Inserts a placeholder for a tensor that will be always fed.

Important: This tensor will produce an error if evaluated. Its value must be fed using the `feed_dict` optional argument to `Session.run()`, `Tensor.eval()`, or `Operation.run()`.

Constructing Graph: First Hidden Layer

이렇게 변수의 이름을 지정해 둔다.

weight 행렬의 크기는 “이전 layer의 노드 개수 * 현재 layer의 노드 개수”이다.

```
w1 = tf.get_variable("w1", [IMG_HEIGHT*IMG_WIDTH*NUM_CHANNEL, 1024])
b1 = tf.get_variable("b1", [1024])
```

```
fc1 = tf.nn.relu( tf.matmul(images_batch, w1) + b1 )
```

Layer1의 출력 벡터이다.

activation 함수로는 sigmoid대신 relu를 적용한다.

images_batch*w1은 [batch_size, 1024] 크기의 행렬이고,
b1은 [1024] 크기의 1차원 벡터이다. 행렬의 각 행에 b1이 더해진다.
이것을 numpy에서는 broadcasting이라고 부른다.

- **Relu (Rectified Linear Unit)은 대표적인 activation 함수이며 다음과 같이 정의된다:**

$$relu(x) = \max(0, x)$$

https://www.tensorflow.org/api_docs/python/tf/get_variable

tf.get_variable

```
get_variable(
    name,
    shape=None,
    dtype=None,
    initializer=None,
    regularizer=None,
    trainable=True,
    collections=None,
    caching_device=None,
    partitioner=None,
    validate_shape=True,
    use_resource=None,
    custom_getter=None,
    constraint=None
)
```

Constructing Graph: Second and Output Layer

```
w2 = tf.get_variable("w2", [1024, 512])
b2 = tf.get_variable("b2", [512])
```

이전 layer의 출력이 이 layer의 입력이 된다.

```
fc2 = tf.nn.relu(tf.matmul(fc1, w2) + b2)
```

```
w3 = tf.get_variable("w3", [512, NUM_CLASS])
b3 = tf.get_variable("b3", [NUM_CLASS])
y_pred = tf.matmul(fc2, w3) + b3
```

출력 layer에는 아직 activation 함수를 적용하지 않았다.
y_pred는 임의의 실수를 원소로 가지는 batch_size * NUM_CLASS 크기의 행렬이다.

Constructing Graph: Loss Function

y_pred는 아직 softmax 함수를 적용하기 전이고,
labels_batch는 one-hot-encoding이 아니다. 이런 상황에서 필요한 모든 일을 대신 처리해주는
함수가 tf.nn.sparse_softmax_cross_entropy_with_logits이다.

```
loss = tf.nn.sparse_softmax_cross_entropy_with_logits(logits=y_pred,
           labels=labels_batch)
```

Loss 함수로 지난 주 이론 수업에서 설명한 mean-square 대신 cross entropy함수를 사용하였다. 본질적인 의미는 동일하다.

만약 labels_batch가 one-hot-encoding되어 있다면
softmax_cross_entropy_with_logits 함수를 대신 사용하면 된다.

```
loss_mean = tf.reduce_mean(loss)
```

loss는 각 이미지별로 따로 계산되므로
1×batch_size 크기의
벡터이다. 여기에서 평균 loss를 계산한다.

- **Cross entropy 함수는 다음과 같이 정의된다. ($\bar{y}$를 one-hot-encoded label, y를 출력이라고 하자. y는 각 클래스에 속할 확률을 나타내는 벡터의 형태를 가진다. 즉, softmax의 출력이다.)**

$$\text{cross\_entropy}(y, \bar{y}) = -\sum \bar{y} \log y$$

- **Mean square loss 함수를 사용하고 싶으면 다음과 같은 식으로 한다.**

```
y_normalized = tf.nn.softmax(y_pred)
loss = (y_normalized - labels) ** 2
loss_mean = tf.reduce_sum(loss)
```

tf.nn.sparse_softmax_cross_entropy_with_logits

```
sparse_softmax_cross_entropy_with_logits(
    _sentinel=None,
    labels=None,
    logits=None,
    name=None
)
```

Computes sparse softmax cross entropy between `logits` and `labels`.

Measures the probability error in discrete classification tasks in which the classes are mutually exclusive (each entry is in exactly one class). For example, each CIFAR-10 image is labeled with one and only one label: an image can be a dog or a truck, but not both.

NOTE: For this operation, the probability of a given label is considered exclusive. That is, soft classes are not allowed, and the `labels` vector must provide a single specific index for the true class for each row of `logits` (each minibatch entry). For soft softmax classification with a probability distribution for each entry, see `softmax_cross_entropy_with_logits`.

WARNING: This op expects unscaled logits, since it performs a `softmax` on `logits` internally for efficiency. Do not call this op with the output of `softmax`, as it will produce incorrect results.

A common use case is to have logits of shape `[batch_size, num_classes]` and labels of shape `[batch_size]`. But higher dimensions are supported.

Note that to avoid confusion, it is required to pass only named arguments to this function.

Constructing Graph: Backpropagation Algorithm

- 지금까지 정의한 모든 노드(텐서)들이 결국 어떤 “값”을 표현 한다면 train_op는 “알고리즘(operation)”을 표현한다.
- train_op 타겟을 run하면 backpropagation이 이루어진다.

```
train_op = tf.train.AdamOptimizer().minimize(loss)
```

loss값을 최소화하는 backpropagation을 실행할 optimizer이다.
역시 지난 주 설명한 gradient descent method 대신 AdamOptimizer를 사용했다.
AdamOptimizer는 gradient descent method에 learning rate (ρ)를 adaptive하게 자동 조절하는 기능이 추가된 버전이라고 생각하면 된다.

- 기본적인 gradient descent method를 쓰려면 다음과 같이 한다. 이 경우 learning rate (ρ)를 지정해야 한다.

```
train_op = tf.train.GradientDescentOptimizer(0.0001).minimize(cost)
```

Running Network: Training

```
sess = tf.Session()
sess.run(tf.global_variables_initializer())
```

지금까지 구성한 그래프를 실행할 session을 생성하고 변수들을 초기화한다.

```
iter_ = train_data_iterator()
for step in range(500):
    images_batch_val, labels_batch_val = next(iter_)

    _, loss_val = sess.run([train_op, loss_mean],
                           feed_dict={
                               images_batch:images_batch_val,
                               labels_batch:labels_batch_val
                           })
    print(loss_val)

print('Training Finished....')
```

이렇게 실행할 타겟을 지정한다.

Python dictionary의 형태로 placeholder에 제공할 데이터를 공급한다.

Running Network: Testing

```
print('Test begins….')
TEST_BSIZE = 50
for i in range(int(len(test_features)/TEST_BSIZE)):

    images_batch_val = test_features[i*TEST_BSIZE:(i+1)*TEST_BSIZE] / 255.
labels_batch_val = test_labels[i*TEST_BSIZE:(i+1)*TEST_BSIZE]

loss_val = sess.run([loss_mean], feed_dict={
                images_batch:images_batch_val,
                labels_batch:labels_batch_val
                })
print(loss_val)
```

- 현재의 코드는 loss값만을 출력한다. 뭔가 되고 있기는 하지만 얼마나 잘 되고 있는지는 알 수 없다. Test에서 정확도(적중율, accuracy)를 출력하려면 어떻게 해야 할까?
- 노드 개수, 이미지 크기 등을 바꿔가면서 정확도를 개선해본다.
- 정확도를 계산하여 출력한 후 스크린 캡쳐 이미지를 홈페이지에 올린다.